



**NULL - Churn**

**Rappi**

## Controle do Documento

### Histórico de revisões

Data	Autor	Versão	Resumo da atividade
10/08/2022	Giovana Lisbôa Thomé	1.1	Atualização da seção 4.4.1
10/08/2022	Pedro Munhoz	1.2	Preenchimento da seção 4.4.1 Preenchimento da seção 4.1.4 Preenchimento da seção 4.2
10/08/2022	Rodrigo Martins	1.3	Preenchimento da seção 4.1.2 Preenchimento da seção 4.2
10/08/2022	Eric Tachdjian	1.4	Preenchimento da seção 4.1.5
14/08/2022	Rodrigo Martins	1.5	Preenchimento da seção 4.2
14/08/2022	Sergio Lucas	1.6	Preenchimento da seção 4.1.3.1 Preenchimento da seção 4.1.3.3 Preenchimento da seção 4.2.1 , 4.2.1.1
14/08/2022	Beatriz Hirasaki Leite	1.7	Preenchimento da seção 4.1.3.2 Preenchimento da seção 4.2.1.3
14/08/2022	Arthur Reis	1.8	Preenchimento da seção 4.1.3 Preenchimento da seção 4.2.3
21/08/2022	Rodrigo Martins	1.9	Preenchimento da seção 4.1.7
24/08/2022	Eric Tachdjian	2.1	Preenchimento da seção 4.1.6
25/08/2022	Giovana Thomé	2.2	Preenchimento da seção 1 e revisão geral do documento
28/08/2022	Eric Tachdjian	2.3	Preenchimento da seção 4.3
28/08/2022	Sergio Lucas	2.4	Atualização da seção 4.1.6
28/08/2022	Beatriz Hirasaki e Pedro Munhoz	2.5	Revisão geral do documento
29/08/2022	Rodrigo Martins	2.6	Preenchimento da seção 4.1.7
29/08/2022	Giovana Thomé	2.7	Atualização da seção 4.3

12/09/2022	Giovana Thomé, Rodrigo Martins e Pedro Munhoz	3.1	Preenchimento da seção 4.4
12/09/2022	Pedro Munhoz	3.2	Preenchimento da seção 4.5
13/09/2022	Giovana Thomé e Pedro Munhoz	3.3	Atualização da seção 4.4
24/09/2022	Giovana Thomé	4.1	Atualização da seção 4.4

# Sumário

<b>1. Introdução</b>	<b>6</b>
<b>2. Objetivos e Justificativa</b>	<b>7</b>
2.1. Objetivos	7
2.2. Justificativa	7
<b>3. Metodologia</b>	<b>8</b>
3.1. CRISP-DM	8
3.2. Ferramentas	8
3.3. Principais técnicas empregadas	8
<b>4. Desenvolvimento e Resultados</b>	<b>9</b>
4.1. Compreensão do Problema	9
4.1.1. Contexto da indústria	9
4.1.2. Análise SWOT	11
4.1.3. Planejamento Geral da Solução	11
4.1.4. Value Proposition Canvas	16
4.1.5. Matriz de Riscos	16
4.1.6. Personas	17
4.1.7. Jornadas do Usuário	19
4.2. Compreensão dos Dados	20
4.2.1. Dados a serem utilizados	20
4.2.2. Descrição estatística básica dos dados	27
4.2.3. Descrição da predição desejada	28
4.3. Preparação dos Dados	29
4.3.1. Descrição de manipulações nos registros e suas respectivas features.	29
4.3.2. Agregação de registros e/ou derivação de novos atributos.	29
4.3.3. Remoção ou substituição de valores ausentes/em branco.	30
4.3.4. Identificação das features selecionadas, com descrição dos motivos de seleção.	31
4.4. Modelagem	32
4.4.1. KNN(K-Nearest Neighbors)	32

4.4.1.1. Explicação do modelo	32
4.4.1.2. Motivo de escolha do modelo	33
4.4.1.3. Resultados obtidos	33
4.4.2 Decision Tree	34
4.4.2.1. Explicação do modelo	34
4.4.2.2. Motivo de escolha do modelo	34
4.4.2.3. Resultados obtidos	34
4.4.3 Naive Bayes	35
4.4.3.2. Motivo de escolha do modelo	36
4.4.3.3. Resultados obtidos	36
4.4.4 Random Forest	36
4.4.4.2. Motivo de escolha do modelo	37
4.4.4.3. Resultados obtidos	37
4.4.5 Regressão Logística	38
4.4.5.2. Motivo de escolha do modelo	38
4.4.5.3. Resultados obtidos	38
4.4.6 Support Vector Machine - SVM	39
4.4.6.1. Explicação do modelo	39
4.4.6.2. Motivo de escolha do modelo	39
4.4.6.3. Resultados obtidos	40
4.5. Avaliação	40
4.6 Comparação de Modelos	42
<b>5. Conclusões e Recomendações</b>	<b>43</b>
<b>6. Referências</b>	<b>44</b>
<b>Anexos</b>	<b>45</b>

# 1. Introdução

O parceiro de negócios no módulo 3 é a empresa Rappi, que atua principalmente no setor de entregas, contendo escopo bastante diversificado incluindo restaurantes, farmácias, supermercados, shoppings, entre outros serviços como viagens e entregas express. A empresa nasceu na Colômbia, atualmente com sede em Bogotá, e é presente em grande parte da América Latina.

Atualmente, no Brasil, a Rappi enfrenta um problema de uma alta taxa de rotatividade (*churn rate*) de seus entregadores em seu aplicativo, sem conseguir reter um grande número deles. São trabalhadores – muitas vezes referidos como RTs – que, em sua maioria, trabalham na Rappi para complementar sua renda. Além da baixa retenção de entregadores, a empresa não tem conhecimento das principais causas de churn em sua plataforma e dos entregadores que são mais propensos a saírem.

## 2. Objetivos e Justificativa

### 2.1. Objetivos

Descreva resumidamente os objetivos gerais e específicos do seu parceiro de negócios

### 2.2. Justificativa

Faça uma breve defesa de sua proposta de solução, escreva sobre seus potenciais, seus benefícios e como ela se diferencia.

## **3. Metodologia**

Descreva as etapas metodológicas que foram utilizadas para o desenvolvimento, citando o referencial teórico. Você deve apenas enunciar os métodos, sem dizer ainda como ele foi aplicado e quais resultados obtidos.

### **3.1. CRISP-DM**

Descreva brevemente a metodologia CRISP-DM e suas etapas de processo

### **3.2. Ferramentas**

Descreva brevemente as ferramentas utilizadas e seus papéis (Google Colaboratory)

### **3.3. Principais técnicas empregadas**

Descreva brevemente as principais técnicas empregadas, algoritmos e seus benefícios



## 4. Desenvolvimento e Resultados

### 4.1. Compreensão do Problema

#### 4.1.1. Contexto da indústria

##### Cinco Forças de Porter

Dado que o modelo preditivo a ser desenvolvido é destinado à Rappi, a análise de mercado em que a empresa está inserida foi feita utilizando o modelo das Cinco Forças de Porter, criado por Michael Porter. O modelo de análise de competição entre as empresas engloba cinco tópicos principais: rivalidade entre os concorrentes, ameaça de novos concorrentes, ameaça de produtos substitutos, poder de negociação dos clientes e poder de negociação dos fornecedores, todos aprofundados a seguir, respectivamente.

No setor de delivery, a rivalidade é alta por conta dos fortes concorrentes já consolidados no mercado, tanto de entrega de comida quanto outros produtos, como compras de supermercado, farmácia, etc. Apesar da empresa dispor de tecnologia assim como seus competidores, a tarefa de captar parceiros de negócio (entregadores, restaurantes, farmácias e supermercados) não é tão exitosa quanto a de seus concorrentes, criando um cenário de concorrência alta.

Já o cenário de entrada de novos concorrentes é bastante chamativo por ser um setor altamente lucrativo e com espaço para inovações. Porém, por conta da rivalidade elevada já mencionada, competidores já consolidados no mercado dificultam bastante a entrada.

Ao mesmo tempo que a utilização de aplicativos de delivery é um substituto para a ida do cliente às lojas físicas, aplicativos de comunicação também podem representar um meio substituto para comunicação remota restaurante cliente, como já é observado atualmente, principalmente em cidades não tão populosas, sem serviços como iFood e Rappi. Um dos maiores exemplos é o Whatsapp, aplicativo de mensagens utilizado em larga escala no Brasil.

Apesar da informação do perfil dos clientes da Rappi não ser aberta ao público, é possível realizar uma análise e apontamentos das características mais generalistas de seus clientes. Pessoas que prezam pela praticidade de recebimento de produtos em casa e pela economia de tempo, além de terem poder de compra e disposição para gastos do gênero são o principal público do aplicativo. Porém, para uma conquista e retenção mais eficaz de usuários, a empresa deve deixar claro seu diferencial das múltiplas opções de produtos dentro do app, caso contrário seus clientes tem certo “poder de negociação” por conseguir facilmente migrar de um serviço de delivery para outro.

Finalmente, os principais fornecedores para esse modelo de negócio são restaurantes, farmácias e mercados (para produtos comercializados) e também o serviço de entregas prestados por terceiros. Como a análise de Porter diz, o aumento do poder de negociação dos

fornecedores causa uma diminuição na lucratividade da empresa, o que pode ser observado atualmente com a rotatividade alta dos entregadores, que demanda maior incentivo por parte da Rappi para mantê-los.

### **Principais players, tendências e modelo de negócios**

Por representar um cenário de mar vermelho, o mercado de vendas online de produtos consumíveis, principalmente alimentos, tem grandes nomes espalhados pelo globo. No Brasil, o principal nome e dono de mais de 80% do market share é a empresa iFood, [lançada em 2011](#). Por outro lado, considerando a América Latina (excluindo o Brasil), o contexto muda e Rappi entra em cena com mais de 60% dos clientes de aplicativos do tipo, tendo o serviço do Uber Eats como seu concorrente em potencial, apesar de não representar grande ameaça por não possuir grande clientela. Já para compras de supermercado online, outro player também entra em jogo, o Cornershop, também da rede Uber. O serviço não oferece entrega de restaurantes ou farmácias e possui um sistema de delivery bastante semelhante a de seus competidores, porém não representa uma ameaça por possuir baixo índice de market share.

Ao falar dos principais players do ramo, todos tendem a manter um avanço tecnológico crescente para sempre melhorar a experiência de seus usuários e fornecedores. Além de seus sistemas internos e o próprio aplicativo, inteligências artificiais têm grande potencial para extração de conhecimento a partir da análise dos dados coletados em larga escala. A tecnologia pode ser utilizada também para melhor atendimento ao cliente, visto que negócios totalmente online tendem a acumular numerosas reclamações. Por fim, uma abordagem levando em conta os princípios ESG (Environmental, Social and Governance) podem trazer maior lucratividade, visto que a corporação trabalhará em cima de assuntos que vão além do seu papel proposto.

Adentrando o modelo de negócios da Rappi, vê-se uma plataforma digital que almeja conectar estabelecimentos aos clientes, fazendo a ponte por meio das entregas com motoristas próprios da Rappi. Esse modelo nasceu com a finalidade de ser a referência da compra online de qualquer produto na América Latina, em que a compra deve chegar o mais rápido possível nas mãos dos clientes no conforto de seus lares. Ou seja, o diferencial da Rappi é a abrangência de sua cobertura, envolvendo não só o serviço de delivery de alimentos, mas também a entrega de itens de farmácia, locação de carros, reserva de hotéis, voos e muito mais!

## 4.1.2. Análise SWOT

Forças	Fraquezas
<ul style="list-style-type: none"><li>• <i>Serviços de entregas diversos (Farmácias, Restaurantes, Mercados, etc)</i></li><li>• <i>Possuí um tempo de resposta rápido para entregas</i></li><li>• <i>Ampla presença no mercado Latino-Americano</i></li><li>• <i>Proporciona incentivos financeiros aos clientes regularmente</i></li></ul>	<ul style="list-style-type: none"><li>• <i>O procedimento de cancelamento para o RT é mal estruturado</i></li><li>• <i>Ineficiência na comunicação de diferenciais</i></li><li>• <i>Suporte técnico ineficiente</i></li><li>• <i>Base de dados de complexo entendimento</i></li></ul>
Oportunidades	Ameaças
<ul style="list-style-type: none"><li>• <i>Aumento da demanda para delivery</i></li><li>• <i>Ascensão da cultura ESG</i></li><li>• <i>Ascensão do Home Office / Híbrido</i></li></ul>	<ul style="list-style-type: none"><li>• <i>Recessão econômica dos países latino-americanos</i></li><li>• <i>Forte concorrência; melhor experiência do usuário, maior área de atuação, consolidação, etc.</i></li><li>• <i>Alta rotatividade de entregadores</i></li><li>• <i>Legislação para entregadores</i></li></ul>

## 4.1.3. Planejamento Geral da Solução

### 4.1.3.1. Qual é o problema a ser resolvido

Não existe um vínculo empregatício entre a Rappi e seus entregadores, logo, não há nenhuma razão para os entregadores questionarem o abandono do uso do aplicativo. Estas saídas influenciam na taxa de rotatividade (“Churn Rate”, em inglês) da empresa, visto que sem os entregadores, não há como o aplicativo oferecer seus diversos serviços ao usuário final e a empresa não gera receita; O problema, então, é manter os entregadores satisfeitos ao utilizar a plataforma.

Este é um problema difícil de enfrentar, com diversas maneiras possíveis de ser abordado, porém, toda solução começa com a compreensão; Os problemas dos entregadores são causados por agentes externos ou pela própria empresa? A comunicação entre eles e a empresa está trazendo resultados tangíveis para serem utilizados nesta compreensão? O que é necessário para a empresa conseguir diminuir a taxa de rotatividade? Responder estas questões é o objetivo de nosso trabalho; o problema a ser resolvido.

#### 4.1.3.2. Quais os dados disponíveis

[Link Colab - análise de dados](#)

#### 4.1.3.3. Qual a solução proposta

Após análise do documento TAPI, é possível montar uma lista de características que terá nossa entrega, seja por necessidade acadêmica, seja por requisição do cliente.

##### **Requisições Acadêmicas**

Como o projeto é realizado também como uma forma de aprendizado, existem algumas padronizações entre todos os projetos:

- **Programa em Python**
  - Considerada uma das melhores linguagens de programação para ser utilizada em machine learning, a principal ferramenta a ser utilizada é o Python
  - Será utilizada a ferramenta “Google Colab”, variante do “Jupyter Notebook” para o desenvolvimento, e o arquivo final terá a extensão .ipynb (IPython Notebook, pode ser aberta somente com Jupyter Notebook e variantes)

##### **Requisições do Cliente**

O cliente descreveu uma potencial saída dos dados, julgamos os pontos mais importantes:

- **Sistema de Pontuação**
  - Ranquear o RT mais propenso a dar churn para o menos propenso a dar churn.
- **Escala percentual de Churn**
  - De 0 à 100%, o quão propenso o RT está a dar churn

##### **Análise de Viabilidade**

Em discussões internas do grupo e com o corpo docente, existem alguns detalhes que valem a pena ser ressaltados:

- **Dados disponibilizados**
  - Com os dados disponíveis, não é possível realizar a produção de uma inteligência artificial supervisionada de característica regressiva; ou seja, não há como ranquear os funcionários com a chance percentual de churn.
- **Integração da Solução**
  - Como o produto do nosso projeto será entregue em como um notebook no Google Colab, não haverá uma integração imediata.

Juntando todas as análises, é possível, neste momento (Sprint 01, 01/08/2022 → 12/08/2022), dizer que a solução pode ser descrita como:

- Código em Python, entregue por meio do Google Colab (extensão .ipynb)
- Inteligência Artificial Supervisionada por Classificação
- Sugestões de possíveis soluções para diminuir o churn de entregadores, baseado nos resultados de análise de dados.

#### **4.1.3.4. Qual o tipo de tarefa (regressão ou classificação)**

A tarefa proposta, por requisição do cliente, deve ser regressiva (entretanto, com os dados fornecidos até o momento, o cumprimento desse requisito se torna inviável).

#### **4.1.3.5. Como a solução proposta deverá ser utilizada**

Nossa solução proposta de modelo preditivo funcionará através de dados fornecidos pelo usuário e inseridos no sistema. Ou seja, o gerente de operações da Rappi fará um levantamento dos acontecimentos ocorridos em um determinado período de tempo e selecionará essas informações para entrada no software. Os dados de rendimento dos entregadores de aplicativo serão postos na plataforma e o nosso algoritmo fará uma leitura concisa do que foi apresentado, ranqueando os trabalhadores com a maior probabilidade de “Churn”; além disso, o modelo também apontará o porquê dos entregadores estarem insatisfeitos com a empresa e auxiliará na tomada de decisão de como a Rappi deve se portar para evitar a perda de mão de obra.

Vale frisar que o usuário precisará coletar os dados e organizá-los de maneira concreta para que o algoritmo consiga fazer uma previsão do abandono desses trabalhadores com erros de dados completamente mitigados. Essa coleta pode ser feita utilizando tabelas, dessa forma, as informações conseguirão ser bem estruturadas e mais simples de serem visualizadas. A partir desse modelo, nosso produto realizará uma leitura dessas tabelas e diagnosticará o problema de “Churn” dos RT's.

Diante disso, o gerente de operações terá um panorama geral de quais trabalhadores possuem os maiores riscos de encerrar os serviços com a Rappi (esse índice pode variar de 0 a 100) e, automaticamente, apontará os problemas mais recorrentes que os entregadores estão enfrentando – por isso os índices de “Churn” mais altos devem receber uma atenção especial. O usuário, por meio do ID do entregador, entrará em contato com ele no aplicativo da Rappi, ou simplesmente poderá melhorar o aplicativo ou as condições de trabalho que dependem dos tipos de reclamações desses entregadores. Os parâmetros do nosso modelo preditivo precisarão ser atualizados e, por conseguinte, cabe ao responsável por utilizar nosso sistema

modificar os pontos específicos dos dados que foram atualizados para que esse processo ocorra dinamicamente.

#### **4.1.3.6. Quais os benefícios trazidos pela solução proposta**

Por se tratar de um modelo preditivo que faz uso de Inteligência Artificial e machine learning, nossa proposta trará, principalmente, o benefício da automatização da informação. Desse modo, nossa proposta facilitará a tomada de decisão do usuário de forma que ela se torne mais rápida e eficiente, uma vez que o algoritmo está programado para entender essa informação, minimizando a necessidade do gerente de operações ter que remediar o problema do churn por não possuir uma previsão de qual entregador pode deixar de trabalhar para Rappi. Ao fundamentar o processo de decisão de maneira eficiente, nosso sistema fará o reconhecimento do problema e buscará uma solução condizente com as necessidades dos entregadores de aplicativo.

Ele se diferencia do método tradicional de análise de dados para a tomada de decisão, porque, sem nosso software, o gerente de operações precisa formar uma equipe para estudar o que os dados de churn significam, organizá-los e, assim, buscar uma solução adequada para cada tipo de problema. Esse processo de remediação não é eficaz no que tange à permanência dos entregadores e as informações do churn, com o passar do tempo, se encontram desatualizadas; ou seja, seria inviável tomar uma decisão efetiva para a resolução do “Churn” dos entregadores. A partir desse cenário, nosso sistema, além de fazer uma interpretação mais eficiente desses dados, como mencionado anteriormente, também possibilitará a atualização das informações de forma simples, por meio da inserção dos parâmetros de dados atualizados sem a necessidade do gasto de um tempo desnecessário para a manutenção do modelo de predição. Esses benefícios trazidos por nossa proposta, faz com que o usuário produza e coloque uma quantidade considerável de dados para serem interpretados e respondidos de maneira mais efetiva.

#### **4.1.3.7. Qual será o critério de sucesso e qual medida será utilizada para o avaliar**

O sucesso de nosso modelo preditivo será pautado, principalmente, na busca de uma classificação para os entregadores que estão com uma probabilidade muito alta do “Churn” e, com isso, auxiliar a evitar esse acontecimento de maneira estratégica, buscando uma solução automática para a solução da insatisfação dos trabalhadores. De acordo com os dados que possuem uma maior destaque, ou seja, aqueles que possuem informações mais críticas e expressam uma perda gigante para o RT, o sistema desenvolverá uma resposta específica para a resolução do risco de “Churn”.

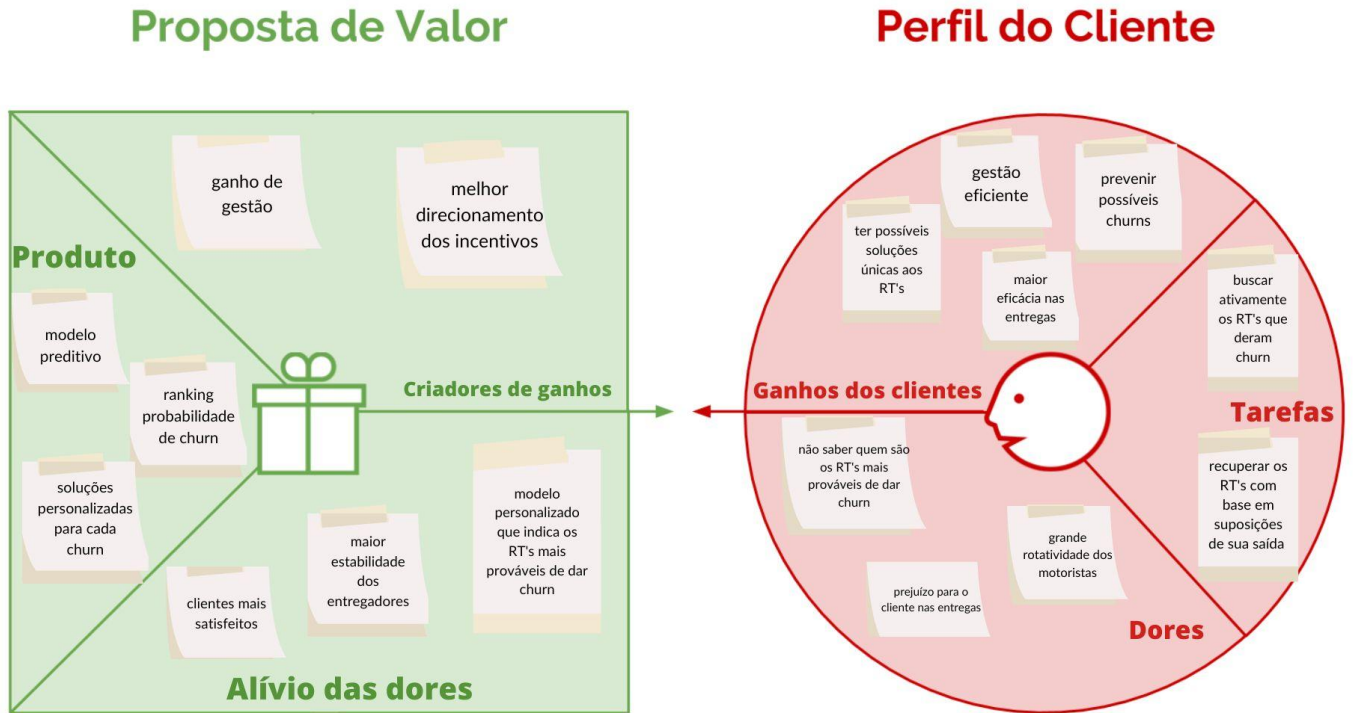
A principal medida a ser utilizada para avaliar o risco de perda dos Rt 's será o quanto de retorno esse entregador possui com os pedidos. Assim, o algoritmo avaliará o lucro, considerando suas perdas e ganhos durante o determinado período de tempo em que os

dados foram coletados. Portanto, o modelo preditivo realizará uma leitura principalmente dos “Earnings” e “Tips” (dados relacionados a receita do entregador e as gorjetas recebidas), o ganho real do trabalhador. Outra medida que nosso sistema considerará está relacionada ao tempo de serviços prestados e como esse tempo foi gasto, avaliando principalmente o “Supply” (Tempo em horas que o Rt ficou/fica conectado no sistema) e “Num\_order” (número de pedidos atendidos por entregador naquele dia).

Depois de realizar essa leitura, o software fará uma outra avaliação dos dados que representa o nível de satisfação e a produtividade do entregador. Essas informações estão contidas, principalmente, em “attendance rate” (taxa de aceitação dos pedidos feitos pelo Rt no aplicativo), “acceptance rate” (número de pedidos aceitos pelo entregador no dia), “orders done” (número de pedidos realizados pelo entregador), “orders cancel” (ordem de pedidos cancelados pela empresa e pelo entregador) e se o trabalhador sofreu algum tipo de punição (“punishment type”, “punishment minutes” e “discipline\_rule\_bucket”).

Diante dessas informações, o modelo preditivo organizará todas essas variáveis após a leitura das mesmas e se o valor numérico dos ganhos dos entregadores forem inferiores ou inversamente proporcionais o seu rendimento e sua produtividade, o software interpretará que esses entregadores possuem um alto risco de “Churn” e criará um ranking de 0 a 100 desses RT’s abordando um motivo de seu principal abandono e a solução para a resolução desse problema. As punições que esse entregador sofreu são relevantes e serão levadas em consideração como terceiro critério de ranqueamento. Depois dessa classificação de entregadores, os problemas aparecerão e, clicando nos comentários desses problemas, o usuário conseguirá obter uma solução logo abaixo da descrição do problema.

#### 4.1.4. Value Proposition Canvas



#### 4.1.5. Matriz de Riscos

	A	B	C	D	E	F	G	H	I	J	K	L	
1			Ameaças						Oportunidades				
2	P r o b a b i l i d a d e	90%							Grupo com capacidades diversas e com muito potencial para ajudar um ao	Conhecer um mercado com potencial enorme, enquanto trabalhamos	Conhecer e compreender a realidade de muitos RTs		
3		70%			Falta de conhecimento prévio atrapalhar o andamento do projeto				Muitas possibilidades de se aprimorar tecnicamente				
4		50%					Escopo ser muito grande e não possibilitar a entrega						
5		30%						Ajudar no dia a dia da Rappi					
6		10%		Problemas pessoais				Trabalho ser abaixo do nível desejado tanto pelos integrantes quanto pelo cliente					
7			Muito baixo	Baixo	Moderado	Alto	Muito alto	Muito alto	Alto	Moderado	Baixo	Muito baixo	
8			Impacto										



## 4.1.6. Personas

Acesso ao arquivo com as personas:

[https://www.canva.com/design/DAFJfATtpbw/SpTRiFrzaZhMJV\\_lqFHVZA/edit?utm\\_content=DAFJfATtpbw&utm\\_campaign=designshare&utm\\_medium=link2&utm\\_source=sharebutton](https://www.canva.com/design/DAFJfATtpbw/SpTRiFrzaZhMJV_lqFHVZA/edit?utm_content=DAFJfATtpbw&utm_campaign=designshare&utm_medium=link2&utm_source=sharebutton)



### Persona 01 - Profissional de Operações Rappi

Daniel Lopes foi construído com alguns entendimentos sobre a empresa e o problema, entre eles estão:

- **Estrutura Técnica** :

A estrutura técnica apresentada pela Rappi se demonstra inadequada para realizar o trabalho eficientemente, com muitos dados sendo de difícil acesso e falta de normalização nas tabelas extraídas.

- **Decisões Difíceis** :


O time de operações se encontra encarregado de entender os problemas e punir apenas aqueles que tentam fraudar o sistema, o que prova ser uma tarefa de difícil execução.

- **Expectativas** :

Apesar das dificuldades, a expectativa é um modelo preditivo com a resposta de quais entregadores darão churn

# Robson Teixeira

Esta pessoa não existe, imagem gerada com auxílio de uma inteligência artificial no site: <https://thispersondoesnotexist.com>



## Biografia

Pai, solteiro, desempregado, afetado pelo cenário econômico brasileiro. Formação técnica em mecânica automotiva, ama automóveis e possui moto própria.

## Objetivos

Garantir segurança financeira, garantir qualidade de vida, principalmente de ensino, para seus filhos, tempo de descanso, lazer com sua família, continuar seus estudos

## Impedimentos

Trabalhar horas além do saudável  
Remuneração baixa  
Dependente da empresa e do cliente que realizou o pedido.  
Blocks injustos

## Necessidades

Segurança financeira, saúde, lazer.  
Prover para seus dependentes  
Ser ouvido



## Desejos

Dar oportunidades para seus filhos, comprar um automóvel esportivo, aumentar seu padrão de vida, ter uma renda estável, obter ensino superior.

## Dores

Instabilidade financeira, ausência de plano de saúde, ausência de direitos, ausência de previdência social, ausência de folga  
Débito com a empresa

## Motivações

Sobrevivência  
Prover financeiramente para seus dependentes  
Esforço para melhora de vida

## Influências

Thiago Nigro - Autor  
Ronaldinho Gaúcho - Jogador de Futebol  
Ayrton Senna - Piloto de corrida F1  
Will Smith - Ator

PERSONA - RAPPITENDERO

## Persona 02 - Entregador Rappi (Rappitendero)

Robson Teixeira foi construído com base em entregadores reais que compartilharam suas opiniões em redes sociais. Com nosso entendimento do problema, os tópicos levantados foram:

- **Cenário Econômico :**

O Brasil está passando por uma fase de recessão econômica e o desemprego é um problema que já se tornou comum nas vidas dos cidadãos. Os entregadores, tanto da Rappi quanto de outros aplicativos, nascem na necessidade de obter renda neste período.

- **Dificuldades:**

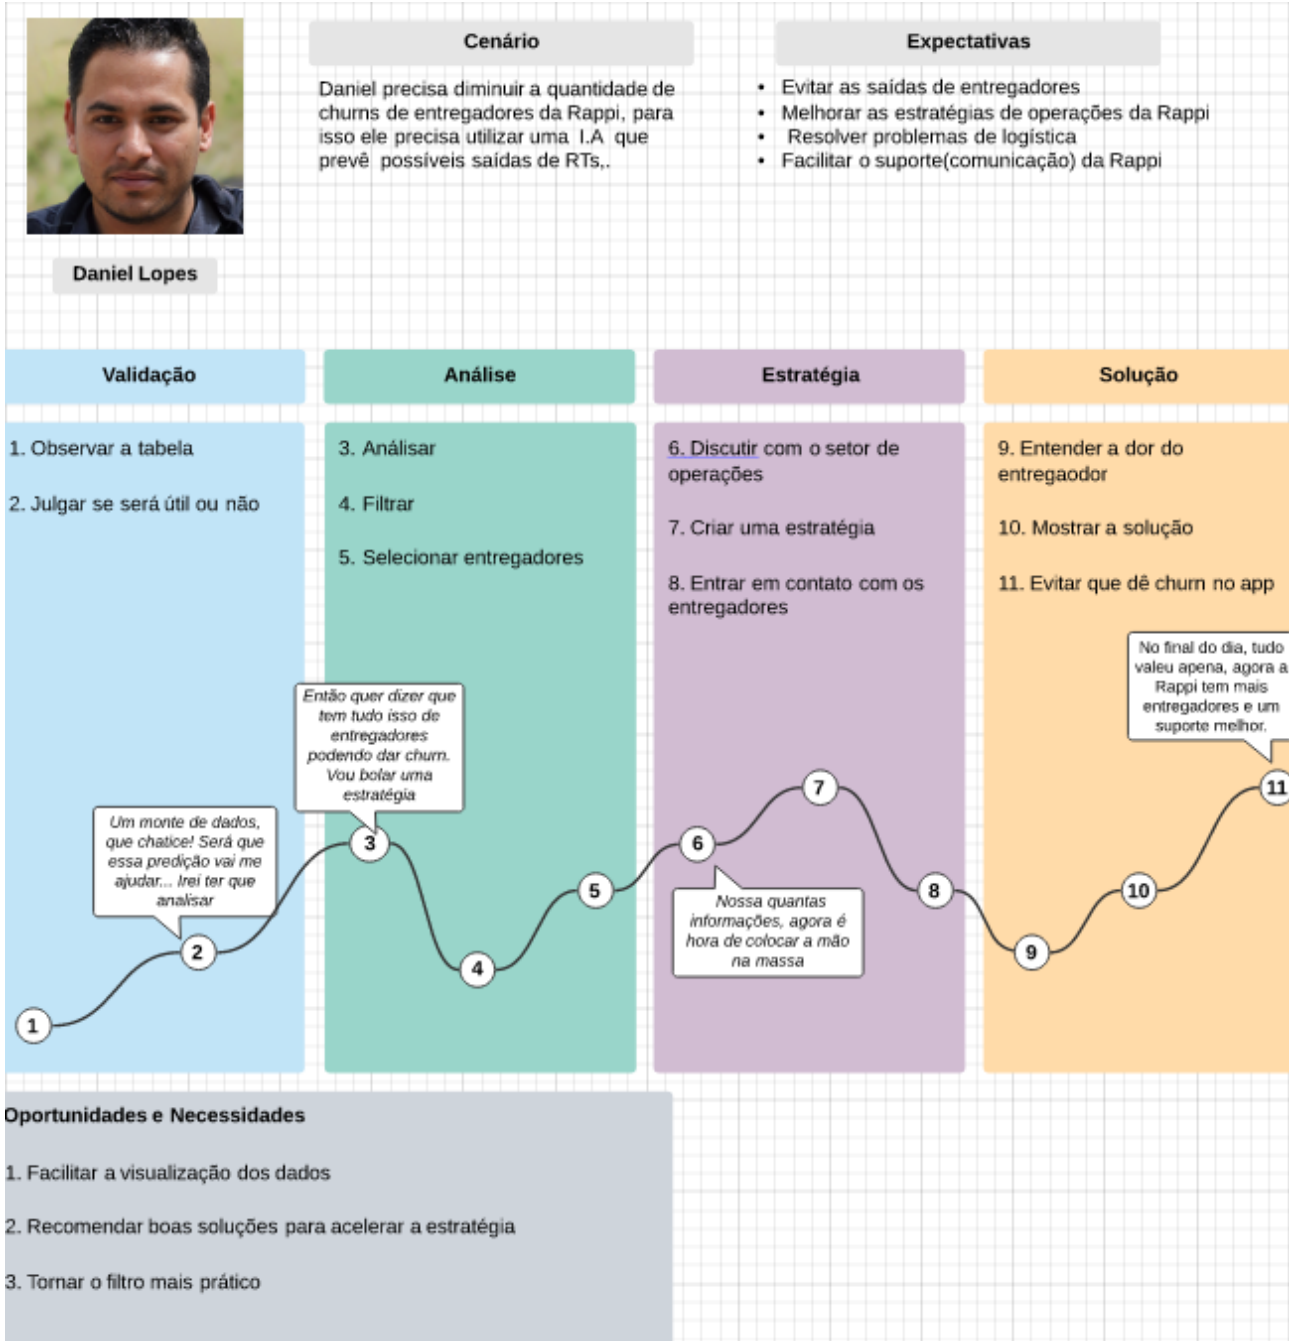
O trabalho em si se apresenta difícil; o pagamento por entrega é inconsistente, o entregador não tem benefícios, direitos trabalhistas, ou plano de saúde, e não tem vínculo empregatício com a empresa, o que gera grande incerteza sobre seu futuro.

- **Imprevisibilidade:**

O churn pode vir de várias formas; insatisfação com a Rappi, uma oferta melhor das empresas competidoras, ou até mesmo a própria saída da profissão de entregador.

# 4.1.7. Jornadas do Usuário

[https://lucid.app/lucidchart/461347e2-da68-4e35-9bed-2548665629f0/edit?viewport\\_loc=-138%2C136%2C3328%2C1606%2C0\\_0&invitationId=inv\\_136bd04f-0ad1-44f1-9c25-9b919dcb8cd3#](https://lucid.app/lucidchart/461347e2-da68-4e35-9bed-2548665629f0/edit?viewport_loc=-138%2C136%2C3328%2C1606%2C0_0&invitationId=inv_136bd04f-0ad1-44f1-9c25-9b919dcb8cd3#)



## 4.2. Compreensão dos Dados

### 4.2.1. Dados a serem utilizados

Até o momento, nos foram disponibilizadas 11 tabelas. O método `df.info()` foi utilizado para obter o tipo de dado de cada coluna, como pode ser visto a seguir na seção `Dtype` das capturas de tela feitas de todas as tabelas:

- **2022-08-10 10\_40am.csv**
  - Conteúdo: Quilometragem
  - Tamanho: 31.382.215 linhas x 4 colunas - 1,29 GB

#### 11. 2022-08-10 - Quilometragem

```
import pandas as pd
df = pd.read_csv('/content/drive/Shared drives/Grupo Rappitendeiros/2022-08-10 10_40am.csv')
df.info()

/usr/local/lib/python3.7/dist-packages/IPython/core/interactiveshell.py:3326: DtypeWarning:
  exec(code_obj, self.user_global_ns, self.user_ns)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 31382215 entries, 0 to 31382214
Data columns (total 4 columns):
#   Column                Dtype
---  -
0   ORDER_ID              int64
1   STOREKEEPER_ID        float64
2   DISTANCE_TO_USER      float64
3   BUNDLE_ID             object
dtypes: float64(2), int64(1), object(1)
memory usage: 957.7+ MB
```

- **attendance\_rate.csv**
  - Conteúdo: Aceitação dos pedidos
  - Tamanho: 653.167 linhas x 2 colunas - 7 MB

#### 4. Attendance rate

```
[6] import pandas as pd

df = pd.read_csv('/content/drive/Shared drives/Grupo Rappitendeiros/attendance_rate.csv')
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 653167 entries, 0 to 653166
Data columns (total 2 columns):
#   Column                Non-Null Count  Dtype
---  -
0   STOREKEEPER_ID        653166 non-null float64
1   ACCEPTANCE_RATE       263051 non-null float64
dtypes: float64(2)
memory usage: 10.0 MB
```

- **comp defects.csv**

- Conteúdo: Reclamações de Pedidos
- Tamanho: 6.783.958 linhas x 10 colunas - 388,9 MB

### 5. Comp Defects

```

import pandas as pd

df = pd.read_csv('/content/drive/SharedDrives/Grupo Rappitendeiros/comp defects.csv')
df.info()

```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6783958 entries, 0 to 6783957
Data columns (total 10 columns):
#   Column              Dtype
---  -
0   STOREKEEPER_ID      float64
1   WEEK                 object
2   CITY                 object
3   LEVEL_ID             float64
4   LEVEL_NAME           object
5   ORDERS               int64
6   GMV_TOTAL            float64
7   COMPENSATIONS        float64
8   DEFECT_COMPENSATIONS float64
9   DEFECT_ORDER         float64
dtypes: float64(6), int64(1), object(3)
memory usage: 517.6+ MB

```

- **criacao contas churn-002.csv**

- Conteúdo: Entregadores que deram churn
- Tamanho: 32.568.384 linhas x 9 colunas - 2,63 GB

### 6. Criação Contas Churn

```

import pandas as pd

df = pd.read_csv('/content/drive/SharedDrives/Grupo Rappitendeiros/criacao contas churn-002.csv')
df.info()

```

```

/usr/local/lib/python3.7/dist-packages/IPython/core/interactiveshell.py:3326: DtypeWarning: Columns (6) have mixed
    exec(code_obj, self.user_global_ns, self.user_ns)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 32568384 entries, 0 to 32568383
Data columns (total 9 columns):
#   Column              Dtype
---  -
0   ID                  int64
1   FIRST_NAME          object
2   GENDER              object
3   CITY               object
4   SK.CREATED_AT::DATE object
5   TRANSPORT_MEDIA_TYPE object
6   CARTAO             object
7   LEVEL_NAME          object
8   FECHA_ULI           object
dtypes: int64(1), object(8)
memory usage: 2.2+ GB

```

- **earnings.csv**

- Conteúdo: Receita de cada entregador

- Tamanho: 566.099 linhas x 4 colunas - 22,2 MB

## 7. Earnings

```
import pandas as pd
df = pd.read_csv('/content/drive/Shareddrives/Grupo Rappitendeiros/earnings.csv')
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 566099 entries, 0 to 566098
Data columns (total 4 columns):
#   Column          Non-Null Count  Dtype
---  -
0   MONTH           566099 non-null object
1   STOREKEEPER_ID  566099 non-null int64
2   EARNINGS        566099 non-null float64
3   TIPS            566099 non-null float64
dtypes: float64(2), int64(1), object(1)
memory usage: 17.3+ MB
```

- **Incidentes\_Regras RT.csv**
  - Conteúdo: Punições
  - Tamanho: 2.405.601 linhas x 9 colunas - 234,2 MB

## 1. Incidentes\_Regras RT

```
[3] import pandas as pd

df = pd.read_csv('/content/drive/Shareddrives/Grupo Rappitendeiros/Incidentes_Regras RT.csv')
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2405601 entries, 0 to 2405600
Data columns (total 9 columns):
#   Column              Dtype
---  -
0   DATE                object
1   NAME                object
2   INCIDENT_ID         int64
3   STOREKEEPER_ID      int64
4   PUNISHMENT_MINUTES  int64
5   PUNISHMENT_TYPE     object
6   DISCIPLINE_RULE_BUCKET object
7   CATEGORY_RULE       object
8   ORDER_ID            float64
dtypes: float64(1), int64(3), object(5)
memory usage: 165.2+ MB
```

- **infos gerais.csv**

- Conteúdo: Informações gerais sobre entregadores ativos
- Tamanho: 180.178 linhas x 25 colunas - 29,9 MB

## 8. Infos Gerais

```
import pandas as pd
df = pd.read_csv('/content/drive/SharedDrives/Grupo Rappitendeiros/infos gerais.csv')
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 180178 entries, 0 to 180177
Data columns (total 25 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   ID                                     180178 non-null int64
1   NOME                                  180158 non-null object
2   SOBRENOME                             180164 non-null object
3   GENERO                                180172 non-null object
4   DATA_NASCIMENTO                      180178 non-null object
5   CIDADE                                180178 non-null object
6   IS_ACTIVE                             180178 non-null bool
7   TRANSPORTE                            180178 non-null object
8   AUTO_ACEITE                           180178 non-null bool
9   COUNT_ORDERS_LAST_7D                  180178 non-null int64
10  COUNT_ORDERS_LAST_30D                 180178 non-null int64
11  COUNT_ORDERS_CANCELED_LAST_7D         180178 non-null int64
12  COUNT_ORDERS_CANCELED_LAST_30D        180178 non-null int64
13  GORJETA                                180178 non-null float64
14  PRIMEIRO_PEDIDO                        180178 non-null object
15  ULTIMO_PEDIDO                          180178 non-null object
16  COUNT_ORDERS_RESTAURANTES              180178 non-null int64
17  COUNT_ORDERS_MERCADO                   180178 non-null int64
18  COUNT_ORDERS_FARMACIA                  180178 non-null int64
19  COUNT_ORDERS_EXPRESS                   180178 non-null int64
20  COUNT_ORDERS_ECOMMERCE                 180178 non-null int64
21  COUNT_ORDERS_ANTOJO                    180178 non-null int64
22  FRETE_MEDIO                            180176 non-null float64
23  COOKING_TIME_MEDIO                     161449 non-null float64
24  ITENS_MEDIO                            179826 non-null float64
dtypes: bool(2), float64(4), int64(11), object(8)
memory usage: 32.0+ MB
```

- **Orders Done e Cancel.csv**

- Conteúdo: Pedidos atendidos e cancelados
- Tamanho: 653.166 linhas x 4 colunas - 9,1 MB

## 2. Ordens Done e Cancel

```
import pandas as pd

df = pd.read_csv('/content/drive/SharedDrives/Grupo Rappitendeiros/Ordens Done e Cancel.csv')
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 653166 entries, 0 to 653165
Data columns (total 4 columns):
#   Column                Non-Null Count  Dtype
---  -
0   STOREKEEPER_ID        653166 non-null int64
1   ORDERS_DONE            653166 non-null int64
2   ORDERS_CANCEL          653166 non-null int64
3   CANCELS_OPS_RT        653166 non-null int64
dtypes: int64(4)
memory usage: 19.9 MB
```

- **Product return.csv**

- Conteúdo: Retorno de pedidos cancelados
- Tamanho: 41.535 linhas x 11 colunas - 4,6 MB

### 3. Product Return

```
[5] import pandas as pd

df = pd.read_csv('/content/drive/Shareddrives/Grupo Rappitendeiros/Product return.csv')
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 41535 entries, 0 to 41534
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  -
0   ID_ENTREGADOR          41535 non-null  int64
1   LEVEL_NAME             41535 non-null  object
2   MODAL                  41535 non-null  object
3   CITY                   41535 non-null  object
4   CREATED_AT             41535 non-null  object
5   ORDER_ID               41535 non-null  int64
6   PRODUCT_RETURNS        41535 non-null  float64
7   VERTICAL_SUB_GROUP     41535 non-null  object
8   COUNT_TO_GMV           41535 non-null  bool
9   GMV                    41535 non-null  float64
10  STORE_ID               41535 non-null  int64
dtypes: bool(1), float64(2), int64(3), object(5)
memory usage: 3.2+ MB
```

- **supply.csv**
  - Conteúdo: Tempo de conexão do RT
  - Tamanho: 124.526 linhas x 10 colunas - 10,1 MB

### 9. Supply

```
[10] import pandas as pd

df = pd.read_csv('/content/drive/Shareddrives/Grupo Rappitendeiros/supply.csv')
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 124526 entries, 0 to 124525
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   CITY                   124526 non-null  object
1   DATE                   124526 non-null  object
2   WEEK                   124526 non-null  object
3   CREATED_CARD           106279 non-null  object
4   STOREKEEPER_ID         124526 non-null  int64
5   LEVEL_NAME_2           113497 non-null  object
6   HAVE_CARD              124526 non-null  int64
7   TRANSPORT_MEDIA_TYPE   124526 non-null  object
8   NUM_ORDERS              104034 non-null  float64
9   SUPPLY_HOURS            124526 non-null  float64
dtypes: float64(2), int64(2), object(6)
memory usage: 9.5+ MB
```



- **tempo resolucao e modal-001.csv**
  - Conteúdo: Tempo de espera pelo suporte
  - Tamanho: 32.568.384 linhas x 9 colunas - 2,63 GB

## 10. Tempo Resolução e Modal

```
import pandas as pd
df = pd.read_csv('/content/drive/Shared drives/Grupo Rappitendeiros/tempo resolutcao e modal-001.csv')
df.info()
```

```
/usr/local/lib/python3.7/dist-packages/IPython/core/interactiveshell.py:3326: DtypeWarning: Columns (6)
  exec(code_obj, self.user_global_ns, self.user_ns)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 32568384 entries, 0 to 32568383
Data columns (total 9 columns):
#   Column                Dtype
---  -
0   ID                     int64
1   FIRST_NAME             object
2   GENDER                 object
3   CITY                  object
4   SK.CREATED_AT::DATE    object
5   TRANSPORT_MEDIA_TYPE  object
6   CARTAO                 object
7   LEVEL_NAME            object
8   FECHA_ULT              object
dtypes: int64(1), object(8)
memory usage: 2.2+ GB
```

○

Todos estes dados são de fonte da própria empresa e de manipulação interna

### 4.2.1.1. Descrição de agregação e mesclagem de dados

Na maioria das tabelas, há uma coluna denominada "STOREKEEPER\_ID", que corresponde ao número de identificação do RT. Desta forma, é possível, por exemplo, mesclar a taxa de aceitação com a renda líquida que o entregador possui.

Também é possível realizarmos visualizações personalizadas, como a relação entre os entregadores que mantêm o auto-aceite ativo com aqueles que deram churn e também mantêm o auto-aceite, entre diversas outras possíveis análises. Com a melhor visualização propiciada pela mescla das tabelas é possível realizarmos validação de hipóteses, como, por exemplo, estipular se os entregadores que deixam o auto-aceite ligado e, por conta disso, recebem mais pedidos dão menos churn.

Um outro método de validação é conversar com o cliente. hjhj

Em nossa visualização, agregamos as seguintes tabelas:

- Earnings
- Distance to Users Level

- Acceptance Rate
- Product Return
- Orders done e Cancel

Elas podem ser visualizadas em maior detalhe no item 4.2.2.

#### **4.2.1.2. Descrição dos riscos e contingências relacionados a esses dados** Recebemos uma ampla variedade de dados, entretanto, cabem algumas ressalvas:

Sobre qualidade: as tabelas enviadas apresentam fatores que complicam a análise, como haver várias colunas com nomes diferentes representando o mesmo conceito – algo contornável com atenção. Ademais, há algumas colunas sem valor, o que prejudica minimamente o modelo preditivo por conta da quantidade massiva de dados, sendo que os campos vazios têm pouca representatividade do todo.

Já no que se refere à cobertura dos dados, o objetivo do modelo preditivo proposto pela Rappi – a classificação de 0 a 100 da probabilidade de um entregador deixar a plataforma – dificilmente conseguirá ser atingido com os dados apresentados até então, uma vez que as informações fornecidas são binárias, isto é, evidenciam com “sim” ou “não” se um entregador deu churn, não havendo uma gradação que permita prever um valor numérico entre os extremos.

O acesso aos dados ocorreu de maneira prevista, sem intercorrências.

A partir dessa análise, pode-se desprender nosso plano de contingência, que envolve a requisição de novos dados para viabilizar a confecção do modelo solicitado pela Rappi, mas, caso não seja possível, pretendemos desenvolver um sistema que explicita quais entregadores são prováveis de dar churn e quais não, mostrando ao usuário da aplicação a relação do nome do entregador com uma marcação “sim” ou “não” para possibilidade de churn.

#### **4.2.1.3. Descrição de como será selecionado o subconjunto para análises iniciais**

Fizemos 5 análises:

- *Taxa de aceitação do entregador:*

Esse gráfico demonstra o nível de aceitação pela densidade. Grande parte dos entregadores aceitam todos os pedidos, mas a variação presente no gráfico se dá devido aos entregadores que não aceitam todos os pedidos. Mas, mesmo com essa variação, o gráfico continua bem distribuído.

- *Taxa de level por conta churn:*

Esse gráfico diz respeito ao nível do entregador com relação às contas churns, ou seja, as contas que o entregador abandonou. Aqui há uma discrepância muito alta, pois podemos ver entregadores de nível alto (bronze) tendo uma taxa de churn muito alta.

Temos duas interpretações para esse gráfico: as contas bronze são maiores (em número), então o número de churn é maior; os entregadores aumentam o rendimento, aumentam o nível, e voltam a deixar o rendimento cair, fazendo com que o nível diminua também. Com isso, eles se frustram e acabam dando churn.

- *Taxa de auto aceite entre entregadores:*

Esse é um gráfico de pizza que demonstra os entregadores que deixam a aceitação dos pedidos automática, ou seja, eles não precisam decidir se vão ou não aceitar, pois já aceitam automaticamente. 60% dos entregadores têm essa função ativa, ou seja, isso significa que a maioria dos entregadores gosta e valida esse auto aceite, muito porque eles têm um rendimento maior e são mais reconhecidos pela Rappi de acordo com nossa análise.

- *Auto aceite entre contas churn:*

Esse gráfico demonstra os entregadores que têm o auto aceite ativo e têm a conta churn, ou seja, estão saindo ou pensam em sair da empresa. 60% mantêm o auto aceite e possuem conta churn, e 40% possuem auto aceite e não deram churn. Com isso, podemos concluir que a maioria dos entregadores que tem o auto aceite ativo deram churn, possivelmente por haver muitos pedidos e a carga de trabalho ser muito pesada, fazendo com que eles se canssem e decidam deixar a empresa pelo baixo retorno.

- *Meios de transporte usados pelos entregadores:*

Esse gráfico demonstra que os entregadores preferem veículos econômicos, em que eles possam gastar menos dinheiro com combustível. Por isso, a maioria utiliza bicicleta e moto.

*Para maior entendimento de cada gráfico, acesse o ponto 4.2.2 dessa documentação.*

#### **4.2.1.4. Descrição das restrições de segurança.**

Uma vez que o modelo elaborado envolve a interpretação de bancos de dados com informações extremamente sensíveis à Rappi, há uma grande preocupação com a segurança dos dados encaminhados e analisados. Sendo assim, o grupo redator dessa documentação se compromete a manter em total confidencialidade qualquer informação contida neste projeto de modelo preditivo, a fim de prezar nosso compromisso para com a empresa.

## **4.2.2. Descrição estatística básica dos dados**

[Link do Colab - descrição estatística](#)

### 4.2.3.Descrição da predição desejada

Nosso modelo preditivo terá foco na análise da satisfação dos entregadores e realizará seu monitoramento, por meio de referenciais, como:

- Receita Líquida do Entregador (Acceptance Rate);
- Gorjetas do Entregador(Tips);
- Nível do Entregador(Level);
- Pedidos Entregues (Orders Done);
- Horas conectadas(Supply);
- Cancelamentos (Cancels\_Ops\_Rt);
- Quilometragem diária(Distance To Users Level);

Esses dados revelam quem será nosso alvo para a elaboração do modelo preditivo. O algoritmo terá como base os dados do RT(mencionados anteriormente), em que será possível estimar a probabilidade de churn deste indivíduo. Dessa forma, o resultado esperado é um ranqueamento dos RTs da Rappi e, em seguida, o possível motivo desse Churn, o que nos leva a propor soluções personalizadas.

Diante disso, podemos observar que essas informações serão muito úteis para a construção de nosso algoritmo, visto que nosso produto se baseará nos ganhos mensais do RT (receita líquida, pedidos entregues e gorjetas), seu rendimento (horas conectadas e nível do entregador) e seus gastos com combustível (podemos calcular o gasto de combustível médio por meio da quilometragem diária). Se os ganhos forem inferiores aos gastos, nosso software ranqueará esse entregador como um caso de alto risco de “Churn”, caso contrário a probabilidade de abandono do entregador será menor.

Um modelo preditivo de inteligência artificial tem como característica a renovação de seus resultados com a inserção de novos parâmetros; ou seja, conforme os eventos de Churn acontecem, a IA também se adapta e atualiza o modelo.

A natureza de nosso modelo preditivo proposta por nosso parceiro de projeto é contínua (regressiva). Visto que sua iniciativa se baseia no ranqueamento dos entregadores por aplicativo e o principal fator para a classificação desses entregadores é a probabilidade de “Churn”. Por se tratar de variáveis numéricas, o risco de abandono desses RT´s está relacionado de forma quantitativa e será expresso por um índice de 0 a 100. Entretanto, a base de dados que nos foi enviada contém somente informações binárias, pois os dados dizem apenas se o entregador deu ou não o “Churn”. Desse modo, precisamos transformar o nosso algoritmo de natureza binária para regressiva, através dos outros dados que nos foram passados.

## 4.3. Preparação dos Dados

Código IPYNB referente aos itens 4.3.1, 4.3.3 e 4.3.4 da feature engineering: [Colab - Feature Engineering](#)


### 4.3.1. Descrição de manipulações nos registros e suas respectivas features.

- *Target* - Utilizando a tabela “*criação contas churn*”, separamos as contas que deram churn e eliminamos as duplicatas. Ao realizar esse processo, obtivemos os IDs necessários e que serão utilizados nas outras features.

```
df_churn.head()
```

	ID	CHURN
0	1286316	True
1	1110698	True
2	284886	True
3	1036587	True
4	106854	True

- *Infos gerais* - Utilizando a informação obtida no “Target”, cruzamos uma das tabelas que contém informações das cidades nas quais os RTs trabalham (tabela “*info gerais*”), obtendo os números de churn por cidade. Como a taxa de churn por cidade é muito semelhante, como pode-se ver no gráfico abaixo, é irrelevante utilizar os dados de cidade dos entregadores como feature.



- *Product return, Cartão, GMV e Punishment type* - Foram alteradas apenas os nomes das colunas das tabelas para padronização.

### 4.3.2. Agregação de registros e/ou derivação de novos atributos.

Código das agregações e derivações: [Colab - Agregações e derivações](#)

- Transformamos o dado "DISTANCE\_TO\_USER", o qual antes da mudança continha a distância por pedidos do entregador, para a soma das distâncias por pedidos, assim criando um dado único para o entregador.
- Transformamos o dado "SUPPLY\_HOURS", o qual antes era um conjunto de dados desagregados das horas ativas no aplicativo por ID, na soma destes dados, indicando apenas um único dado total por ID.
- Mesclamos o dado "ORDERS\_DONE" com "ORDERS\_CANCEL" para calcular o rendimento total do entregador ("ORDERS\_DONE\_RATE") (tabela: *Ordens Done e Cancel.csv*).
- Modificamos o dado "EARNINGS", o qual se referia às várias quantias por mês do entregador, pela média dessas quantias, transformando em apenas um dado total por ID.
- O cálculo de "EARNINGS\_PER\_ORDER" e "EARNINGS\_PER\_DISTANCE" foi feito utilizando o quanto o entregador ganhou dividido pela quantidade de entregas realizadas e km andados para a entrega, respectivamente (tabela: *earnings.csv* e *2022-08-10 10\_40am.csv*).
- O "STOREKEEPER YEAR" foi calculado utilizando o dia, o mês e o ano de nascimento do RT (tabela: *infos gerais.csv*).

#### 4.3.3. Remoção ou substituição de valores ausentes/em branco.

- Na tabela "*eliminação de contas churn*", eliminamos os IDs duplicados.
- Na tabela "*infos gerais*", selecionamos as cidades com o maior número de contas e desconsideramos algumas cidades com nomes que não as representavam, como por exemplo a cidade que tinha o nome "10".
- Removemos as duplicatas para a criação da feature "*Cartão*" na tabela "*criação de contas churn*".
- Em linhas gerais, os valores nulos/ausentes foram preenchidos com 0.

#### 4.3.4. Identificação das features selecionadas, com descrição dos motivos de seleção.

- Feature “Cidades” - Criamos essa feature com o objetivo de verificar quais cidades possuíam uma maior quantidade de churns para possíveis usos no futuro. O resultado dessa feature foi diferente do esperado e todas as cidades com quantias consideráveis de entregadores tinham uma taxa de churn parecida, por isso não utilizamos no modelo.
- Feature “Cartão” - Criamos essa feature para verificar se o RT que deu churn possuía ou não o cartão da Rappi. Nós a criamos pois esperávamos que a posse do cartão teria impacto direto com a decisão do motoqueiro de deixar o app pelas supostas dívidas contraídas.
- Feature “STOREKEEPER\_YEAR” - Transformamos o ano de nascimento do RT na idade real dele. Essa feature foi criada para verificar se a idade faz ou não diferença na decisão do churn e caso faça, no futuro seja de fácil reconhecimento.
- Feature “ORDERS\_DONE\_RATE” - Criado para verificar a porcentagem de sucesso na entrega de cada entregador. Caso o entregador esteja com uma taxa de entrega baixa, pode ser um sinal de fragilidade quanto ao churn. Um entregador pode “falhar” na entrega quando ele, o cliente ou a operação da Rappi cancele o pedido.
- Feature “EARNINGS\_PER\_ORDER” e “EARNINGS\_PER\_DISTANCE” - Como diferentes entregadores trabalham um período diferente de tempo, o valor bruto acumulado não é um fator decisivo para descobrir se aquele motoqueiro pode dar churn, por isso criamos essas duas features, que têm a função de dividir o dinheiro ganho pela quantidade de pedidos e pela distância percorrida pelo RT, respectivamente. Ela serve para mostrar qual o real ganho do entregador.

## 4.4. Modelagem

[Link para Google Colaboratory de modelagem](#) – sprint 3

Em primeira análise, vale constatar que dentre as inúmeras possibilidades de algoritmos pré-prontos que embasam a solução de Inteligência Artificial proposta, nosso grupo escolheu propositalmente 8 algoritmos principais. A escolha de cada modelo será desenvolvida logo nos próximos tópicos, sendo eles: K Nearest Neighbour - KNN, Decision Tree, Naive Bayes, Random Forest, Regressão logística, Support Vector Machines - SVM, Ada Boost e Extra Trees.

Como o objetivo da Rappi é obter uma predição com Inteligência Artificial que evidencie quais entregadores tendem a dar Churn e, após alinhamento com o representante da empresa, foi constatado que é preferível que o modelo inclua trabalhadores que não tendem a deixar a plataforma do que deixar de fora aqueles que podem dar Churn. O parâmetro de avaliação da predição foi, principalmente, a acurácia do modelo, isto é, qual a porcentagem de predições corretas dentre todas realizadas, e a revocação, que indica a porcentagem de Churn que o modelo considerou dentre todos que, de fato, deram Churn, deixando nas entrelinhas uma pequena taxa se houver Churns que o modelo não considerou, ou seja, falsos negativos, sendo essa uma métrica fundamental de ser próxima de 0 por requisição do cliente.

Uma vez que foram fornecidas distintas tabelas com informações separadas que se relacionavam somente pelo ID do entregador, foi constatado que não havia uma relação perfeita, isto é, há dados como o salário do entregador que estavam nulos para alguns ID's. Então, ao fazer a junção das tabelas, existiam linhas com valores nulos em alguns campos importantes. Como solução temporária, foi decidido remover essas linhas, a fim de que sejam mantidos somente valores coletados. Na mesma linha de pensamento, foi observado que, após a limpeza, a quantidade de entregadores que deram Churn estava bem desproporcional em relação àqueles que não deram, sendo esse um grande problema para a Inteligência Artificial, por envia-la a prever o valor mais recorrente (churn positivo). A partir disso, foi necessário igualar as amostras e o caminho escolhido foi descartar valores da maior amostra, até que ela se igualasse com a menos presente. Esse balanceamento, undersampling, pode ser observado na imagem abaixo, e foi escolhido para não criar valores artificiais:

```
CHURN
1      78024
0      21115
dtype: int64
```

```
CHURN
0      21115
1      21115
dtype: int64
```


### 4.4.1. KNN(K-Nearest Neighbors)

#### 4.4.1.1. Explicação do modelo

O modelo K-Nearest Neighbours foi importado da biblioteca *sklearn.neighbours* e funciona pela classificação de padrões que prediz o resultado a partir do cálculo da distância



entre o novo dado de treinamento inserido ainda não classificado e seus vizinhos dentro de um raio específico, como é ilustrado na imagem ao lado.



Idealmente, o número K de vizinhos deve ser ímpar para que suas previsões não fiquem divididas entre 50% de decisão. Além disso, quanto maior o número de vizinhos selecionados, maior será a tendência da classificação ser a mesma, uma vez que a previsão é baseada nos valores mais próximos e não pela quantidade absoluta.

#### 4.4.1.2. Motivo de escolha do modelo

O modelo KNN foi um dos escolhidos porque utiliza um modelo de classificação por padrões de características semelhantes entre todas as ocorrências das features, sendo interessante por possuímos uma grande amostra, que possibilita incluir valores dentro de uma faixa já existente, ou seja, teoricamente sempre haverá algum dado próximo para servir de referência. Como foram escolhidas mais de três features, não é possível fazer um mapeamento visual de proximidade de ocorrências para melhor análise da classificação, uma vez que cada feature corresponde a um eixo do gráfico, sendo um modelo com mais de 3 dimensões.

#### 4.4.1.3. Resultados obtidos

Ao rodar as features selecionadas com dados rebalanceados utilizando a técnica de undersampling, os seguintes resultados foram obtidos:

Acuracidade (treino): 0.7083993181290915


Acuracidade (teste): 0.6345642401562758

Revocação: 0.6339616995810892

Precisão: 0.8654466729300274

F1\_score: 0.7318353741731577


Matriz de confusão:



## 4.4.2 Decision Tree

### 4.4.2.1. Explicação do modelo

O modelo de classificação de árvore de decisão consiste em um conjunto de escolhas hierárquicas, separadas entre nós internos e externos (folhas). Ao utilizar esse modelo, é especificada a profundidade de decisões feitas pela árvore, isto é, quantos níveis de escolhas serão feitas. Para não ocorrer overfitting na classificação, os níveis de decisão não devem ser tão profundos na fase de treino do modelo.



### 4.4.2.2. Motivo de escolha do modelo

O modelo foi escolhido por analisar os padrões de forma binária, onde cada nó da árvore é destrinchado em dois outros nós por meio de uma condição. As condições são feitas com base em padrões encontrados nos dados e, assim, os dados novos inseridos são classificados. Por conta dessa análise de padrões por similaridade dos dados, a árvore de decisão é um dos modelos escolhidos para classificação do projeto, por apresentar uma lógica que pode ser válida.

#### 4.4.2.3. Resultados obtidos

Acuracidade (treino): 0.6701197308829018


Acuracidade (teste): 0.6665725246534397

Revocação: 0.6545780969479353

Precisão: 0.8929344054859382

F1\_score: 0.7553997824548075

Matriz de confusão:



#### 4.4.3 Naive Bayes

##### 4.4.3.1. Explicação do modelo

$$P(H|E) = \frac{P(E|H) * P(H)}{P(E)}$$

Likelihood of the Evidence given that the Hypothesis is True

Prior Probability of the Hypothesis

Posterior Probability of the Hypothesis given that the Evidence is True

Prior Probability that the evidence is True

O modelo Naive Bayes foi importado da biblioteca `sklearn.naive_bayes` e funciona a partir da suposição da independência entre variáveis do problema, realizando uma classificação probabilística de observações, caracterizando-as em classes pré-definidas. Sendo um modelo para a classificação de atributos discretos, o Naive Bayes tem aplicações na análise de crédito, diagnósticos médicos ou busca por falhas em sistemas mecânicos.

É interessante saber que o Naive Bayes é um dos modelos mais conhecidos a aplicar o conceito de probabilidade. Esse modelo, como o nome indica, faz uso do teorema de Bayes como princípio fundamental ( $P(A/B)=P(B/A)P(A)/P(B)$ ). Essa fórmula indica que a probabilidade de um evento A ocorrer é o produto da probabilidade de um evento B ocorrer dado que A ocorreu pela a probabilidade de um evento A ocorrer, dividido pela probabilidade de um evento B ocorrer. Desse modo, o algoritmo calcula a chance de um fenômeno ocorrer novamente, sendo bem aplicável a lógica de indicar se uma pessoa dará Churn com base em um histórico.

#### 4.4.3.2. Motivo de escolha do modelo

O modelo Naive Bayes foi escolhido pela facilidade que o algoritmo possui em calcular a probabilidade de um evento ocorrer no futuro dado que ocorreu no passado. Sendo assim, o Naive Bayes nos proporciona analisar quais entregadores possuem a maior chance de dar Churn, baseado em seu rendimento de trabalho e quanto essa produtividade corroborou no abandono do trabalhador do aplicativo. O modelo usa um método efetivo para prever a probabilidade de classe diferente com base em vários atributos, assim ele realiza a leitura de todas as nossas features escolhidas e como elas influenciaram nas contas Churn e calcula chance de ocorrência desse fenômeno de saída dos entregadores do aplicativo da Rappi para o novo dataset.

#### 4.4.3.3. Resultados obtidos

Acuracidade (treino): 0.7532252695710063


Acuracidade (teste): 0.7526653957494881

Revocação: 0.8586175942549371

Precisão: 0.8322457147829113

F1\_score: 0.8452259974373701


Matriz de confusão:



## 4.4.4 Random Forest

### 4.4.4.1. Explicação do modelo

O modelo de Random Forest foi importado da biblioteca `sklearn.ensemble` e funciona como um conjunto de árvores de decisões (decision trees) randômicas, criando uma gama de escolhas hierárquicas. Portanto, o output desse algoritmo vem da quantidade majoritária da classificação de todas as árvores, ou seja, o resultado da predição é fruto daquele resultado que mais aparece em árvores separadas.



### 4.4.4.2. Motivo de escolha do modelo

O modelo foi escolhido pela métrica da precisão e por ter a possibilidade de ser melhorado devido a quantidade de hiperparâmetros, além de que, se esse modelo se mostrar o melhor, é possível indicar a porcentagem de certeza que o modelo tem de que o entregador dará Churn ou não, a partir de quantas vezes o resultado em questão apareceu em cada árvore separadamente.

### 4.4.4.3. Resultados obtidos

Acuracidade (treino): 0.6642390986392842


Acuracidade (teste): 0.6637247287533244

Revocação: 0.6547277079593058

Precisão: 0.8883881445391799


F1\_score: 0.7538673557278207

Matriz de confusão:



## 4.4.5 Regressão Logística

### 4.4.5.1. Explicação do modelo



Em linhas gerais, os pontos colocados no espaço dimensional, como visto na imagem acima, são binários, isto é, representam 0 ou 1 e a partir da proximidade entre os pontos de valor 1 é traçada uma curva logarítmica que servirá de referência para a predição. Quanto mais próximo o valor a ser predito estiver dessa curva, maior é a probabilidade desse valor ser 1, ou seja, corresponder ao Churn em nosso modelo.

De forma aprofundada, o modelo de regressão logística foi importado da biblioteca `sklearn.linear_model` e modela a probabilidade de um evento de dois possíveis resultados ocorrer, fazendo com que as probabilidades logarítmicas para o evento sejam uma combinação linear de uma ou mais variáveis independentes ("preditores"). Na análise de regressão, a regressão logística (ou regressão logit) está estimando os parâmetros de um modelo logístico. Formalmente, na regressão logística binária existe uma única variável dependente binária, codificada por uma variável indicadora, onde os dois valores são rotulados como "0" e "1", enquanto as variáveis independentes podem ser cada uma uma variável binária (duas classes, codificadas por uma variável indicadora) ou uma variável contínua (qualquer valor real). A

probabilidade correspondente do valor rotulado "1" pode variar entre 0 (certamente o valor "0") e 1 (certamente o valor "1"), daí a rotulagem; a função que converte log-odds em probabilidade é a função logística, daí o nome. para a escala log-odds é chamado de logit, de logistic unit, sendo esses, nomes alternativos.

#### 4.4.5.2. Motivo de escolha do modelo

O modelo de regressão logística foi escolhido porque ele é capaz de prever um fenômeno ou resultado (se o entregador dará churn ou não), por meio das características e comportamentos dos RT 's (experiência, tempo conectado no aplicativo, quilômetros rodados e etc.). Analisando essas informações, o modelo de regressão logística calcula a probabilidade do evento estudado ocorrer, ou seja a chance de nosso target em questão acontecer (nesse caso, o abandono dos entregadores). Esse processo se baseia nas informações descritas anteriormente, e, assim, analisa como as variáveis explanatórias (preditoras) se relacionam com a nossa variável dependente(target).

#### 4.4.5.3. Resultados obtidos

Acuracidade(treino): 0.737257789568182


Acuracidade(teste): 0.7347313422297536

Revocação: 0.7930281268701377

Precisão: 0.8588974948958097

F1\_score: 0.8246495636075112


Matriz de confusão:



## 4.4.6 Support Vector Machine - SVM

### 4.4.6.1. Explicação do modelo

O modelo SVM foi importado da biblioteca `sklearn.svm` e tem a funcionalidade de traçar uma reta que separa os tipos de classificação, tentando maximizar a distância entre os dados de diferentes classificações e esta reta que separa-los.



### 4.4.6.2. Motivo de escolha do modelo

O algoritmo é excelente com uma quantidade grande de features e com dados não regulares. Além disso, o modelo possui uma vasta quantidade de parâmetros que podem ser utilizados para melhorar o desempenho do modelo, adaptando-se ao possível as features.

### 4.4.6.3. Resultados obtidos

Acuracidade (treino): 0.7100434743138422

Acuracidade (teste): 0.7095718891948505


Revocação: 0.735966487133453

Precisão: 0.8749288560045532

F1\_score: 0.7994539426639797

Matriz de confusão:





## 4.4.7. AdaBoost

### 4.4.7.1. Explicação do modelo

Adapting Boosting é um modelo realizado em fases. Primeiramente, um modelo considerado “fraco” em questões de predição é utilizado e, com base nos resultados obtidos, ele aprende os padrões de erros progressivamente para realizar novos treinamentos em novos modelos até chegar em um resultado que o algoritmo acha satisfatório. A partir disso, é criada uma adaptação que, na maioria dos casos, não terá underfitting nos resultados classificadores e alcançará um resultado personalizado após várias melhorias.

### 4.4.7.2. Motivo de escolha do modelo

Por aprender com os próprios erros progressivamente, o Adaboost combina diversos modelos preditivos para retornar resultados e é uma boa opção para classificação por evidenciar uma combinação de modelos que dificilmente seria alcançada na tentativa e no erro.

### 4.4.7.3. Resultados obtidos

Acuracidade (treino): 0.8015412703376068


Acuracidade (teste): 0.7981359881381064

Revocação: 0.9710951526032316

Precisão: 0.8100336952452265

F1\_score: 0.8832823025107165

Matriz de confusão:



## 4.4.8. Extra Trees

### 4.4.8.1. Explicação do modelo

Extra Trees é um modelo bastante semelhante ao Random Forest, com a diferença de adicionar um fator de aleatoriedade a mais na separação de dados. Após a seleção aleatória das variáveis candidatas para o nó inicial, os dados existentes em cada uma destas variáveis serão separados (split dos dados) também de maneira aleatória. Em seguida, os cálculos necessários para a otimização da árvore podem começar.

### 4.4.8.2. Motivo de escolha do modelo

O modelo foi utilizado para comparação de resultados com seus dois modelos semelhantes (Decision Tree e Random Forest), tomando conhecimento se o fator de aleatoriedade a mais do Extra Trees tem um diferencial grande nos resultados, porém houve um overfitting nos dados de treinamento do modelo.

### 4.4.8.3. Resultados obtidos

Acuracidade (treino): 1.0


Acuracidade (teste): 0.79168726023206

Revocação: 0.9353680430879713

Precisão: 0.8236937103106637

F1\_score: 0.8759860447520701

Matriz de confusão:



Os seguintes modelos foram testados utilizando hiperparametrização, ou seja, foram testadas inserções de parâmetros diferentes dentro de cada modelo de classificação. Em cada modelo, será especificado o motivo de escolha de suas respectivas features e hiperparâmetros, assim como análise dos resultados obtidos.

[Link do arquivo do Colab de testes de modelos com hiperparametrização](#)

## 4.4.8. KNN com hiperparâmetrização

### 4.4.8.1. Motivo de escolha do modelo e conjunto de dados

O modelo KNN foi escolhido, porque é um algoritmo muito utilizado para resolver problemas de classificação. Ou seja, podemos testar variáveis numéricas e a partir da interpretação dos números ele retorna uma classe(valor nominal). Além disso, decidimos também escolher esse modelo como uma solução compatível para resolver o problema da Rappi por um outro motivo. O KNN analisa quais características dos vizinhos mais próximos são mais visíveis para relacionar com o target. Assim sendo, ele traça uma reta que mais se aproxima no conjunto de pontos e características desses vizinhos que nesse caso são os próprios entregadores.

Os principais conjuntos de dados que foram escolhidos pelo nosso grupo para a construção do modelo KNN foram o 'CHURN'( target do problema que significa se o entregador saiu do aplicativo no período em que se foram coletados os dados),'EARNINGS PER DISTANCE'(quanto que o entregador ganhou no ano por quilômetro rodado nas entregas),'DISTANCE TO USER'(quanto o entregador percorreu no ano fazendo entregas)e 'Orders Cancel"(quantos pedidos cancelados foram sofridos pelo entregador, contando os cancelamentos feitos pela equipe de operações da Rappi, os pedidos cancelados por ele e os cancelados pelo próprio cliente).

```
[ ] # definição de x e y para treinamento e testagem dos modelos
x = df_final[['EARNINGS_PER_DISTANCE', 'DISTANCE_TO_USER', 'ORDERS_CANCEL']]
y = df_final['CHURN']
```

#### 4.4.8.2. Configurações de hiperparâmetros

Os hiperparâmetros selecionados contribuíram para especificar como o modelo deve ser treinado. Visto que eles são referência de como o algoritmo em questão irá se comportar. Por exemplo, o modelo KNN é definido como pontos das coordenadas e cada ponto (nesse caso, o entregador) possui uma característica que atribuímos a eles na escolha das features escolhidas para treino e teste, mencionadas anteriormente. Desse modo, os parâmetros que colocamos dizem respeito principalmente à quantos vizinhos ou pontos de coordenadas nosso algoritmo quer analisar, o peso de cada ponto, com que qualidade ele avaliará esses pontos e como estão a região onde existem essas coordenadas(sejam mais concentradas ou espalhadas). Esses hiperparâmetros são capazes de melhorar a eficiência do modelo, principalmente no que diz respeito à acurácia de treino e teste.

```
# definir o espaço possível dos hiperparametros a serem testados no modelo
parametros = {'n_neighbors': [3, 5, 7, 9, 13, 17, 21, 29],
              'weights': ['uniform', 'distance'],
              'algorithm': ['auto', 'ball_tree', 'kd_tree', 'brute'],
              'leaf_size': [15, 30, 45, 60]}

# achando os hiperparâmetros e treinando o modelo
knn_grid_search = GridSearchCV(estimator = KNeighborsClassifier(), param_grid=parametros)
knn_grid_search.fit(x_train, y_train.squeeze())
print(knn_grid_search.best_score_)
print(knn_grid_search.best_params_)
```

*hiperparâmetros escolhidos para o modelo KNN*

#### 4.4.8.2. Resultados obtidos

Antes de analisar os resultados obtidos com os hiperparâmetros, é necessário ver os resultados do modelo KNN sem a construção desses mesmos hiperparâmetros:

```
# modelo de classificação K-Nearest Neighbours
from sklearn.neighbors import KNeighborsClassifier

## instanciação do objeto e treinamento do modelo KNN
knn = KNeighborsClassifier(n_neighbors=3).fit(x_train, y_train.squeeze())
# predição do modelo
y_pred = knn.predict(x_test)
metricas(knn)

Acuracidade (treino): 0.9578113750899928
Acuracidade (teste): 0.9074246892381201
Revocação: 0.884833981453784
Precisão: 0.9264015032884435
F1_score: 0.9051407588739289
```

Partindo desse ponto, pode-se analisar os resultados obtidos do algoritmo de vizinhança com os hiperparâmetros inclusos:

```
## instanciación do objeto e treinamento do modelo KNN
knn = KNeighborsClassifier(n_neighbors=3, leaf_size=15, weights='distance').fit(x_train, y_train.squeeze())
# predição do modelo
y_pred = knn.predict(x_test)
metricas(knn)
```

Acuracidade (treino): 0.9998880089592832  
Acuracidade (teste): 0.9337787898017843  
Revocação: 0.8925366437331738  
Precisão: 0.972539113428944  
F1\_score: 0.9308220246451412

*Resultados com hiperparâmetros, considerando os 3 vizinhos mais próximos do algoritmo*

```
## instanciación do objeto e treinamento do modelo KNN
knn = KNeighborsClassifier(n_neighbors=9, leaf_size=15, weights='distance').fit(x_train, y_train.squeeze())
# predição do modelo
y_pred = knn.predict(x_test)
metricas(knn)
```

Acuracidade (treino): 0.9998880089592832  
Acuracidade (teste): 0.9500541266937922  
Revocação: 0.9262638348788513  
Precisão: 0.9723661485319517  
F1\_score: 0.9487552661815396

*Resultados com hiperparâmetros, considerando os 9 vizinhos mais próximos do algoritmo*

```
## instanciación do objeto e treinamento do modelo KNN
knn = KNeighborsClassifier(n_neighbors=9, leaf_size=15, weights='distance').fit(x_train, y_train.squeeze())
# predição do modelo
y_pred = knn.predict(x_test)
metricas(knn)
```

Acuracidade (treino): 0.9998880089592832  
Acuracidade (teste): 0.9500541266937922  
Revocação: 0.9262638348788513  
Precisão: 0.9723661485319517  
F1\_score: 0.9487552661815396

*Resultados com hiperparâmetros, considerando os 17 vizinhos mais próximos do algoritmo:*

```
[ ] ## instanciación do objeto e treinamento do modelo KNN
knn = KNeighborsClassifier(n_neighbors=17, leaf_size=15, weights='distance').fit(x_train, y_train.squeeze())
# predição do modelo
y_pred = knn.predict(x_test)
metricas(knn)
```

Acuracidade (treino): 0.9998880089592832  
Acuracidade (teste): 0.9610661092239352  
Revocação: 0.9486239904277595  
Precisão: 0.9727014799478567  
F1\_score: 0.9605118691553401

A partir desses resultados, pode-se analisar que independentemente de quantos vizinhos mais próximos o algoritmo escolher, o que realmente importa são, de fato, os hiperparâmetros, pois eles especificam o trabalho do modelo KNN e melhoram a eficiência do algoritmo.

## 4.4.9. Extra Trees com hiperparametrização

### 4.4.9.1. Motivo de escolha do modelo e conjunto de dados

Escolhemos o modelo Extra Trees porque o algoritmo cria diversas relações com as features que são inseridas nela. Essas mesmas relações formam árvores. Essas árvores procuram entender quais dos dados inseridos e as features escolhidas para o treino e teste do modelo possuem mais relação com o target(Churn). Quando o algoritmo chega a conclusão de qual relação é a melhor, ele aponta a certeza desse resultado obtido(eficácia do modelo).

O conjunto de dados que foram escolhidos para a construção do modelo Extra Trees foram 'DAILY HOURS'(quantidade de horas que o entregador manteve conectado no aplicativo), 'DAILY ORDERS'(quantidade de pedidos feitos diariamente),'MONTHLY EARNINGS'(receita mensal do entregador),'MONTHLY TIPS'(quantidade de gorjetas recebidas pelo entregador em um mês),'DISTANCE PER ORDER'(quantos pedidos o entregador fez por quilômetro) e 'DAILY DISTANCE'(quantos quilômetros os entregadores percorreram por quilômetro) e o Churn(target do modelo que mostra se o entregador saiu do aplicativo durante o período da coleta desses dados).

```
# definição de x e y para treinamento e testagem dos modelos
x = df_final[['DAILY_HOURS','DAILY_ORDERS','MONTHLY_EARNINGS','MONTHLY_TIPS','DISTANCE_PER_ORDER','DAILY_DISTANCE']]
y = df_final['CHURN']

# rebalanceamento oversampling dos dados x y de treino
from imblearn.over_sampling import RandomOverSampler
rus = RandomOverSampler(random_state=0)
x_resampled, y_resampled = rus.fit_resample(x, y)

print(y_resampled.value_counts())
```

*features que foram escolhidas em nosso código.*

### 4.4.9.2. Configurações de hiperparâmetros

Configuramos os hiperparâmetros para uma melhoria na eficiência do modelo dizendo a respeito principalmente como as árvores serão formadas e como será a construção desse algoritmo, assim sendo se os hiperparâmetros forem ajustados, a formação de nó da árvore será feita de maneira diferente.

```
from sklearn.model_selection import GridSearchCV

parameters={'criterion':['gini','entropy','log_loss'],
            'max_features':['int','float','auto','sqrt','log2']}

modelET = GridSearchCV(estimator=ExtraTreesClassifier(), param_grid=parameters)

modelET.fit(x_train, y_train)
print(modelET.best_score_)
print(modelET.best_params_)
```

*hiperparâmetros escolhidos para o modelo Extra Trees.*

### 4.4.9.3. Resultados obtidos

Antes de analisar os resultados obtidos, precisamos analisar também os resultados obtidos antes da construção desses hiperparâmetros:

```
# modelo de classificação Extra Trees
from sklearn.ensemble import ExtraTreesClassifier

# instânciação do objeto e treinamento do modelo Extra Trees
et = ExtraTreesClassifier().fit(x_train, y_train)
# predição do modelo
y_pred = et.predict(x_test)
metricas(et)
```

```
Acuracidade (treino): 1.0
Acuracidade (teste): 0.9145469052158979
Revocação: 0.9003633996854152
Precisão: 0.9262100711396289
F1_score: 0.9131038655647081
```

E agora analisaremos os resultados obtidos com os hiperparâmetros:

```
# instânciação do objeto e treinamento do modelo Extra Trees
et = ExtraTreesClassifier(criterion='gini', max_features='auto').fit(x_train, y_train)
# predição do modelo
y_pred = et.predict(x_test)
metricas(et)
```

```
Acuracidade (treino): 1.0
Acuracidade (teste): 0.9138977916615955
Revocação: 0.8993328632640886
Precisão: 0.9258731887092722
F1_score: 0.9124100645196791
```

Assim sendo, podemos concluir que mesmo com uma queda de resultado do modelo, a construção desses hiperparâmetros ajudou bastante, porque o algoritmo está mais próximo da realidade, sendo completamente improvável uma acuracidade no treino de 100%, assim sendo o modelo Extra Trees se aproxima muito mais da realidade.

## 4.5. Avaliação

Para melhor visualização do melhor modelo, conferir a tabela abaixo sobre os modelos e as métricas, sendo 100% o resultado ideal, embora esse alvo possa indicar um overfitting, que indica que o modelo acertou todas as vezes que tentou prever aquela métrica específica:

	ACC (treino)	ACC (teste)	Revocação	Precisão	F1 Score
K Nearest Neighbor - KNN	70,83%	63,45%	63,39%	86,54%	73,18%
Decision Tree	67,01%	66,65%	65,45%	89,29%	75,53%
Naive Bayes	75,32%	75,26%	85,86%	83,22%	84,52%
Random Forest	66,42%	66,37%	65,47%	88,83%	75,38%
Regressão Logística	73,72%	73,47%	79,30%	85,88%	82,46%
Support Vector Machines - SVM	71,00%	70,95%	73,59%	87,49%	79,94%
AdaBoost	80,15%	79,81%	97,10%	81,00%	88,32%
Extra Trees	100,00%	79,16%	93,53%	82,36%	87,59%

Tendo como prioridade os indicadores ACC (acurácia) e Revocação, explicados anteriormente como a taxa de acerto totais e o acerto de Churns, respectivamente, também se fazem úteis os indicadores de precisão – qual a porcentagem dos entregadores que deram Churn realmente o modelo indicou que daria, evidenciando os falsos positivos (continua no app) –, e o F1 Score, que é uma média harmônica entre a Revocação e a Precisão. Assim, podemos categorizar os resultados obtidos com base em todos esses indicadores.

Desse modo, torna-se mister lembrar o objetivo da solução proposta, que é apontar, no mundo real, quais entregadores tendem a deixar de serem entregadores ativos na plataforma da Rappi. Então, como a Inteligência leva a uma tomada de decisão que impacta diretamente no setor financeiro da empresa, já que investimentos serão dados a partir de indicações



específicas, o modelo deve ser o mais preciso possível. Por isso, a taxa média de 75% de acerto obtida no conjunto dos testes, indica que em 25% das vezes o modelo deve errar a predição. Esse valor foi, a priori, visto como passível de ser melhorado.

O grande erro na solução não necessariamente é fruto de modelos improdutivos, mas, como citado anteriormente, pode ter ocorrido por escolhas de features ineficazes ou até mesmo um balanceamento que compromete a predição por descartar informações preciosas.

Tendo em vista os testes e modelos apresentados, o mais eficaz, em nossa percepção, é o **AdaBoost**, que apresentou a maior média tanto na acurácia, quanto na revocação e demais parâmetros. Assim, novos testes serão realizados a fim de melhorar esse e outros modelos, para que o resultado seja o mais fidedigno à realidade possível.

## 4.6 Comparação de Modelos

## 5. Conclusões e Recomendações

Escreva, de forma resumida, sobre os principais resultados do seu projeto e faça recomendações formais ao seu parceiro de negócios em relação ao uso desse modelo. Você pode aproveitar este espaço para comentar sobre possíveis materiais extras, como um manual de usuário mais detalhado na seção “Anexos”.

Não se esqueça também das pessoas que serão potencialmente afetadas pelas decisões do modelo preditivo e elabore recomendações que ajudem seu parceiro a tratá-las de maneira estratégica e ética.

## 6. Referências

Nesta seção você deve incluir as principais referências de seu projeto, para que seu parceiro possa consultar caso ele se interessar em aprofundar.

Utilize a norma ABNT NBR 6023 para regras específicas de referências. Um exemplo de referência de livro:

SOBRENOME, Nome. **Título do livro**: subtítulo do livro. Edição. Cidade de publicação: Nome da editora, Ano de publicação.

<https://medium.com/measurable-ai/2021-brazil-food-delivery-ifood-continues-to-lead-with-over-80-market-share-9eaa8b3cb954>

<https://www.salesforce.com/br/customer-success-stories/ifood/#:~:text=Desde%20o%20lan%C3%A7amento%20do%20Grupo,para%20clientes%20em%20diferentes%20localidades>

# Anexos

Utilize esta seção para anexar materiais como manuais de usuário, documentos complementares que ficaram grandes e não couberam no corpo do texto etc.